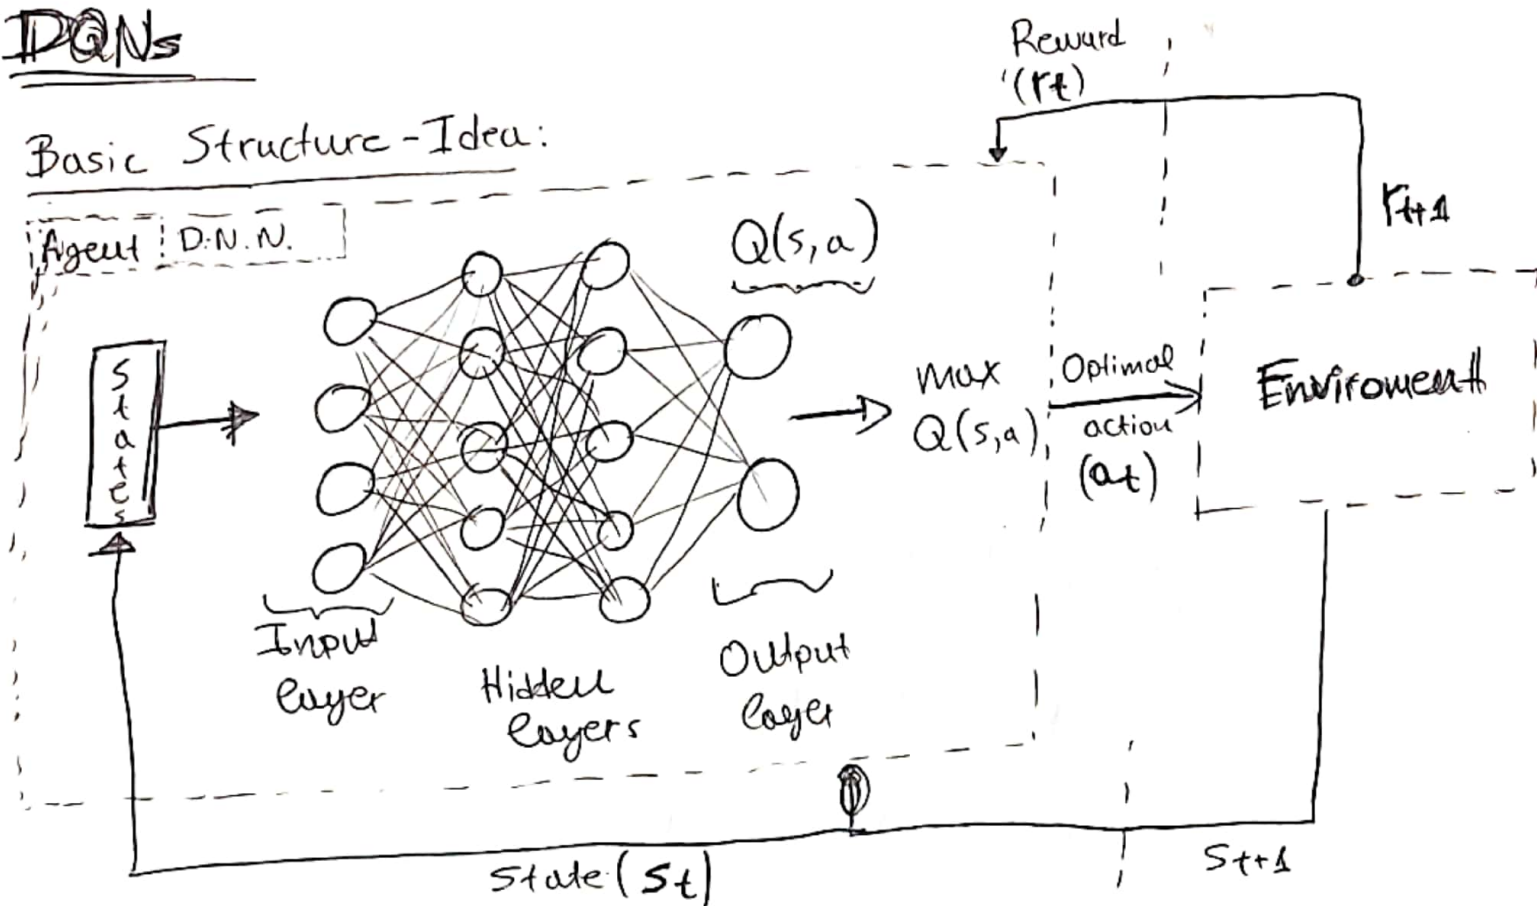


# DQNs

Basic Structure - Idea:



Q-learning function:  $Q(s, a) = r + \gamma \max_{a'} Q(s', a')$

Проблема! Пробегаем по всем  $Q(s', a')$ ,  $\forall (s', a') \rightarrow$  inefficiency.

Solution: Deep Q-Network.

Updating Q-learning function = Bellman Equation!

$$Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$$

learning rate  $\alpha$   
 Discount factor (How much we value the future)  $\gamma$   
 intermediate reward  $r$   
 target  $Q(s, a)$   
 current  $Q(s, a)$

Καταλαβαίνουμε ότι νευρωνικό μας πρέπει να ελαττωσώνισει των

$$Q(s,a) - [r + \gamma \max_{a'} Q(s',a')] \leftarrow \text{loss function}$$

Target network

- Τα  $Q(s,a), Q(s',a')$  δεν πρέπει να υπολογίζονται με τον ίδιο τρόπο  
- Δεν έχει νόημα!

Φτιάχνουμε δύο δίκτυα νευρωνικά:  $\begin{cases} \text{policy-net} \leftarrow \{ \text{αποφασιστική} \} \\ \text{target-net} \leftarrow \{ Q(s',a') \} \end{cases}$

Τα βάρη του policy-net ανακινούνται συνεχώς, ενώ του target-net περιοδικά.

Δ Notation: Βάρη policy:  $\Theta$ , Βάρη target:  $\Theta'$ .

DQN Bellman Equation:  $Q(s,a) \leftarrow Q(s,a) + \underbrace{e[r + \gamma \max_{a'} Q(s',a'; \Theta') - Q(s,a; \Theta)]}_{\text{loss function}}$

\*

Μέχρι τώρα:  $\begin{cases} \text{Αρχιτεκτονική} \checkmark \\ \text{Loss function για υπολογισμό των βαρών} \checkmark \end{cases}$

\* Το target-net θα φέρνεται smoothly, (soft update) ως εξής:

$$\Theta' \leftarrow \tau \Theta + (1-\tau) \Theta', \text{ όπου } \tau \ll 1.$$

Πως τρέφουμε train:

- Selecting action: ~~επιλέγουμε~~ ένα epsilon  
οπότε παίρνουμε τυχαίο αριθμό  $x \in [0,1)$

Αν  $x < \text{epsilon}$  τότε: random-action  $\leftarrow$  Exploration

Αλλιώς: χρησιμοποιούμε το policy-net  $\leftarrow$  Exploitation

⌊ This is called epsilon greedy policy.



## • Calculating the reward

Depends on the environment,

- General Rules
- small ~~and~~ <sup>and</sup> dense rewards > large and sparse ones
  - give penalties to control learning.
  - be creative, there is no single best solution

## • Experience Replay

Αποθηκεύουμε στα μνήμη το (state, action, next state, reward)  
για κάθε action που κάνουμε. Έτσι μπορούμε να υπολογίσουμε το  
loss σε batches των experiences που έχουμε μαζέψει και  
τέλικά να ανακρίνουμε τα βάρη.